

Caso1 grupal

Pronóstico de Ventas de Ropa de Mujer por Zona

Sharid Rodríguez ^{1a,c}, Juan Davis Manosalva ^{2a,c}, Laura Catalina Ariza ^{3a,c},

Juan Garcia Diaz^{b,c}

^A*Estudiantes de Ciencia de datos e ingeniería industrial*

^b*Profesor, Departamento de Ingeniería Industrial*

^c*Pontificia Universidad Javeriana, Bogotá, Colombia*

BUSINESS UNDERSTANDING

1. Determine Business Objectives

1.1 Background

La industria de la moda en Colombia constituye uno de los subsectores más dinámicos del comercio minorista nacional. Según Inexmoda, el sector textil-confección genera más de 450,000 empleos directos y representa alrededor del 8% del PIB industrial del país, con ventas por catálogo como uno de sus canales más relevantes fuera de las grandes superficies. En este contexto, la capacidad de anticipar la demanda a nivel zonal es una ventaja competitiva directa.

El presente proyecto aplica la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) para desarrollar modelos predictivos de las ventas anuales de ropa de mujer de Aura Chic, un detallista colombiano especializado en moda y joyería por catálogo. El dataset de entrenamiento contiene 1,600 observaciones zonales y 12 variables

operativas, comerciales y sociodemográficas, con la variable objetivo ropamujer medida en pesos colombianos.

1.2 Análisis PESTLE

2.1.1 Factor Político-Legal

Colombia presenta un entorno político con relativa estabilidad normativa para el sector comercial, aunque la informalidad del 60% en el mercado laboral (DANE, 2020) representa un riesgo de redistribución del ingreso disponible. La Ley de Protección de Datos Personales (Ley 1581 de 2012) exige a empresas como Aura Chic estrictos protocolos de gestión de bases de datos de clientes, tanto en recolección como en uso predictivo. Los acuerdos de libre comercio con EE.UU. y la UE han generado presión sobre precios de prendas importadas, favoreciendo relativamente a los productores nacionales dentro del segmento popular-medio.

2.1.2 Factor Económico

El crecimiento del PIB colombiano para 2019 fue de 3.3% (DANE), con proyecciones de contracción en 2020 producto de la pandemia (estimado: -6.8%). La inflación promedio 2019-2020 se situó en 3.8%, afectando directamente el poder adquisitivo del segmento objetivo de Aura Chic. Las tasas de financiación del consumo —crédito de libranza y tarjetas— son el mecanismo dominante para compras por catálogo en estratos 2 a 4, que concentran el 68% de la clientela de la empresa. La devaluación del peso (TRM promedio 2020: \$3,693/USD) encareció insumos y telas importadas, presionando márgenes brutos.

2.1.3 Factor Socio-Cultural

Colombia tiene una estructura demográfica favorable para el consumo de moda femenina: el 51.4% de la población es femenina (DANE, 2018) y el rango etario 25-45 —principal segmento de Aura Chic— representa el 27% de la población total. La cultura del catálogo físico mantiene arraigo en ciudades intermedias y zonas rurales donde la penetración del e-commerce sigue siendo limitada (<28% en municipios fuera de las cinco principales ciudades, según CCCE 2020). La identidad regional influye fuertemente en preferencias de

color, talla y estilo, lo que refuerza la relevancia de modelos predictivos con segmentación geográfica.

2.1.4 Factor Tecnológico

El comercio electrónico colombiano creció un 38% en 2020 respecto a 2019 (CCCE), alcanzando \$30.2 billones en transacciones. Esta aceleración digital representa una amenaza de sustitución para el canal catálogo físico y, simultáneamente, una oportunidad si se integra con plataformas digitales. La disponibilidad de datos transaccionales históricos y la maduración de herramientas de machine learning aplicado al retail permiten a empresas como Aura Chic transitar de decisiones basadas en intuición hacia decisiones basadas en modelos predictivos zonal-temporales.

2.1.5 Factor Ambiental

Las regulaciones de sostenibilidad y la presión de consumidores jóvenes por moda responsable están reconfigurando las cadenas de suministro textil. Aunque el impacto inmediato sobre Aura Chic es moderado, la tendencia hacia fibras recicladas y producción local limpia representa un factor diferenciador de mediano plazo. Colombia produjo aproximadamente 98,000 toneladas de residuos textiles en 2019 (ANDI), lo que abre conversaciones sobre economía circular en el sector.

2.1.6 Factor Legal

Las normas de protección al consumidor (Estatuto del Consumidor, Ley 1480 de 2011) regulan las prácticas de venta directa y por catálogo, incluyendo condiciones de devolución, garantías y publicidad. El incumplimiento puede derivar en sanciones de la SIC de hasta 2,000 SMMLV. La Ley 2155 de 2021 (reforma tributaria) impone IVA del 19% a prendas de vestir superiores a \$240,000 COP, segmento que incluye parte del portafolio premium de Aura Chic.

1.3 Fuerzas de Porter

Rivalidad entre competidores existentes — ALTA

El mercado de moda por catálogo en Colombia está dominado por actores como Leonisa, Crédit, Yanbal y Avon, con participaciones combinadas superiores al 55% del

segmento (Euromonitor, 2020). La competencia se da principalmente en precio, cobertura geográfica y amplitud de portafolio. La baja diferenciación del producto en el segmento masivo incrementa la presión competitiva. Aura Chic compete en nichos de precio medio-bajo donde la fidelización de la clientela depende de la calidad del servicio al cliente y la efectividad del catálogo físico.

Amenaza de nuevos entrantes — MODERADA

Las barreras de entrada incluyen: redes de distribución físicas en zonas de difícil acceso, confianza establecida con la clientela y acceso a crédito directo. Sin embargo, plataformas de e-commerce como SHEIN o Linio han reducido las barreras para nuevos competidores digitales que operan sin estructura logística propia, erosionando márgenes en segmentos de precio sensible.

Poder de negociación de proveedores — MODERADO

La cadena textil colombiana cuenta con proveedores nacionales consolidados (Fabricato, Coltejer) y creciente participación de proveedores asiáticos vía importación directa. La dependencia de insumos importados expone a Aura Chic a riesgo cambiario. La concentración moderada de proveedores confiere poder de negociación parcial, mitigado por el volumen de compra y la diversificación geográfica de proveedores.

Poder de negociación de clientes — MODERADO-ALTO

La clientela de Aura Chic —mujer de estrato 2-4, entre 28 y 55 años— tiene acceso creciente a plataformas de comparación de precios y alternativas digitales. Su sensibilidad al precio es alta. No obstante, la fidelidad al catálogo físico y la facilidad del crédito directo generan costos de cambio emocionales y operativos que retienen a parte de la base de clientes.

Amenaza de productos sustitutos — ALTA

El comercio electrónico, las tiendas de segunda mano (segunda mano y consignación), las plataformas de moda rápida y el canal de tiendas físicas de cadena (Éxito, Falabella) constituyen sustitutos directos del catálogo físico. La aceleración post-pandemia del comercio digital eleva esta amenaza a nivel alto, exigiendo a Aura Chic una estrategia de integración omnicanal.

1.4 Análisis SWOT

La siguiente matriz sintetiza los factores internos y externos que condicionan el desempeño de Aura Chic:

FORTALEZAS • Red de distribución establecida en zonas rurales y ciudades intermedias • Base de datos de clientes con historial transaccional de más de 5 años • Sistema de crédito directo que fideliza a la clienta y reduce barreras de compra • Conocimiento profundo del segmento femenino de estratos 2-4	DEBILIDADES • Presencia digital incipiente frente a competidores nativos digitales • Dependencia del catálogo físico en un entorno de digitalización creciente • Ausencia de modelos analíticos formales para planificación de demanda • Exposición a riesgo cambiario por insumos importados
OPORTUNIDADES • Penetración del crédito de libranza en empleados públicos y privados • Crecimiento del mercado femenino de moda en ciudades intermedias • Adopción de analítica predictiva para optimización del inventario y catálogo • Integración omnicanal catálogo-digital para ampliar base de clientes	AMENAZAS • Crecimiento del e-commerce: +38% en 2020 (CCCE) como sustituto directo del catálogo • Contracción del ingreso disponible en estratos 2-4 por efectos post-pandemia • Entrada de competidores digitales con modelos logísticos más eficientes • Volatilidad cambiaria que incrementa costos de insumos importados

El análisis evidencia que el uso estratégico de analítica de datos permite mitigar debilidades internas (dependencia de datos, ineficiencias), capitalizar oportunidades (crecimiento del sector, canales digitales) y responder de manera más efectiva a las presiones competitivas.

1.5 Business Goal

BG1. Mejorar la precisión del pronóstico de demanda anual de ropa de mujer por zona, superando en al menos un 15% el desempeño del modelo base de medias históricas..

BG2. Identificar las variables zonales con mayor influencia sobre las ventas de ropa de mujer y evaluar si modelos segmentados por tipo de mercado mejoran la capacidad predictiva respecto a un modelo global.

Tabla 1. KPIs de Business Goal

Objetivo de Negocio	KPI	Meta	Plazo
ON-01: Precisión pronóstico	RMSE en CV-10 vs. baseline	Reducción $\geq 15\%$ en RMSE y MAPE < 20% en conjunto de validación	Ciclo analítico actual
ON-02: Variables influyentes	Coefficientes estandarizados del modelo Stepwise BIC final	Top-3 variables identificadas e interpretadas en términos de negocio	Entrega del modelo final

2. Determine Data Mining Goals

2.1 Data Mining Goal

- DG1. Desarrollar y comparar modelos predictivos de regresión para estimar las ventas anuales de ropa de mujer (*ropamujer*) por zona, utilizando variables comerciales, operativas y de segmentación del negocio.
- DG2. Identificar las variables con mayor capacidad explicativa sobre la demanda de ropa de mujer y evaluar cómo influyen las estrategias operativas y comerciales en el comportamiento de las ventas zonales.
- DG3. Evaluar si la incorporación de técnicas de feature engineering —como transformaciones, interacciones y splines— mejora el desempeño predictivo frente a modelos contruidos únicamente con variables originales.

2.2 Data Mining Success Criteria

Objetivo	KPI	Criterio de éxito
DG1. Modelo predictivo de demanda	RMSE en validación cruzada (CV-10)	Obtener un RMSE inferior a 11,000 COP y mejorar el desempeño de las primeras rondas de modelado.
	Comparación Stepwise vs. LASSO	Seleccionar automáticamente el modelo con menor error de generalización en validación cruzada.
DG2. Identificación de variables relevantes	Correlaciones e importancia de variables	Identificar las variables con mayor influencia sobre <i>ropamujer</i> y proporcionar interpretación de negocio coherente con los hallazgos del EDA

Estabilidad de variables seleccionadas		Mantener consistencia en las variables más relevantes entre las rondas avanzadas del modelo final.
DG3.	Reducción	Lograr una disminución
Evaluación del feature engineering	porcentual del RMSE	del RMSE respecto al modelo base sin ingeniería de variables.
	Mejora progresiva por rondas	Evidenciar reducción iterativa del RMSE tras incorporar splines, interacciones y transformaciones derivadas.

3. Data Understanding

3. 1 Describe data:

3.1 Descripción General del Dataset

El dataset de entrenamiento comprende 1,600 observaciones correspondientes a unidades de análisis zonales de Aura Chic, con 8 variables que capturan dimensiones comerciales, sociodemográficas y operativas. La variable objetivo es ropamujer, que representa las ventas anuales de ropa de mujer en pesos colombianos (COP) por zona.

Variable	Tipo	Unidad/Escala	Descripción
edadloc	Continua	Años (1–25)	Edad promedio del local o punto de venta
correo	Continua	Unidades	Volumen de correo directo enviado a la zona
paginas	Continua	Páginas (51–114)	Páginas del catálogo asignadas a la zona

telefono	Continua	Llamadas	Contactos telefónicos registrados en la zona
impresa	Continua	COP	Ventas brutas por publicidad impresa
servicio	Continua	Índice (15–68)	Índice de nivel de servicio al cliente en la zona
nomina	Continua	COP	Nómina promedio de empleados en la zona
ropamujer	Continua	COP	VARIABLE OBJETIVO: ventas anuales ropa de mujer

3.2 Análisis Exploratorio Univariado

Con el objetivo de comprender el comportamiento individual de las variables numéricas del conjunto de entrenamiento (train), se realizó un análisis univariado utilizando estadísticas descriptivas y distribuciones gráficas. Este análisis permite identificar patrones de centralidad, dispersión, asimetría y posibles valores extremos que tienen implicaciones directas tanto para la interpretación del negocio como para las decisiones de preparación y modelado de datos.

	n	Media	Mediana	Desv_std	Min	Max	Asimetria
edadloc	1600	10.47	9.00	7.39	1.00	25.00	0.47
correo	1600	10598.68	10480.00	2400.67	1147.00	15259.00	-0.97
paginas	1600	85.04	84.00	15.94	51.00	114.00	-0.05
telefono	1600	37.64	36.00	9.75	17.00	59.00	0.42
impresa	1600	28834.62	28734.79	6251.17	18061.20	40027.78	0.06
servicio	1600	43.65	43.00	13.24	15.00	68.00	0.01
nomina	1600	24104.13	18886.50	18217.35	901.00	135882.00	1.55
ropamujer	1600	50978.38	49968.34	17558.26	1289.24	117709.26	0.31

Figura 1. Tabla de estadísticas descriptivas: n, media, mediana, desviación estándar, mínimo, máximo y asimetría por variable.

La tabla de estadísticas descriptivas evidencia una marcada heterogeneidad entre las variables del negocio y revela características distribucionales relevantes para el desarrollo

del modelo predictivo. En particular, la variable objetivo **ropamujer** presenta una media de \$50,978 COP y una mediana de \$49,968 COP, con una asimetría moderada (0.31), lo que indica una distribución relativamente cercana a la simetría. Esta propiedad resulta favorable para modelos de regresión, ya que reduce la probabilidad de sesgos severos en la estimación. Sin embargo, el amplio rango de ventas observado —desde \$1,289 hasta \$117,709 COP— evidencia una alta heterogeneidad entre zonas comerciales, sugiriendo la coexistencia de mercados con dinámicas de demanda muy diferentes. Esta dispersión justifica el uso del RMSE como métrica principal de evaluación, debido a su sensibilidad frente a errores grandes en zonas de alto volumen de ventas.

La variable **nomina** exhibe el comportamiento más crítico desde el punto de vista estadístico, con una asimetría positiva de 1.55 y una diferencia considerable entre media y mediana. Este patrón indica que un subconjunto reducido de zonas concentra valores de nómina extremadamente altos, generando una cola larga hacia la derecha. Desde la perspectiva del modelado, esta característica puede afectar la estabilidad de modelos lineales y aumentar la influencia de observaciones extremas sobre los residuos; por ello, el análisis sugiere la conveniencia de evaluar transformaciones logarítmicas o métodos robustos para reducir el efecto de outliers y mejorar la linealidad de la relación con la variable objetivo.

Por otro lado, la variable **correo** presenta una asimetría negativa significativa (-0.97), lo que indica que la mayoría de las zonas reciben volúmenes relativamente altos de catálogos, mientras que pocas zonas presentan niveles bajos de envío. Este comportamiento sugiere una estrategia comercial intensiva y relativamente homogénea en la distribución de correo directo, aunque también podría reflejar un sesgo operativo hacia zonas históricamente más rentables. En términos analíticos, esta concentración de valores altos puede limitar parcialmente la capacidad discriminativa de la variable en ciertos rangos del modelo.

En contraste, variables como **impresa** y **paginas** presentan coeficientes de asimetría cercanos a cero, indicando distribuciones relativamente simétricas y una asignación más uniforme de recursos publicitarios entre zonas. Este comportamiento sugiere que las diferencias en ventas no dependen exclusivamente de la inversión publicitaria tradicional, sino posiblemente de factores asociados a segmentación de mercado, intensidad operativa o características específicas de cada zona.

Finalmente, la variable **edadloc** presenta una asimetría positiva moderada (0.47), indicando que la mayoría de las zonas tienen una antigüedad relativamente baja, aunque existen algunos puntos de venta considerablemente más maduros. Desde la perspectiva del negocio, esta variable puede actuar como un indicador indirecto de estabilidad operativa, posicionamiento de marca y consolidación comercial en determinadas zonas geográficas.




Figura 2. Histogramas de las variables numéricas del conjunto de entrenamiento (*train*).

Los histogramas permiten complementar el análisis estadístico al evidenciar visualmente la forma de las distribuciones y la presencia de posibles concentraciones o colas extremas. En particular, la distribución de *nomina* confirma la fuerte asimetría positiva observada en las estadísticas descriptivas, mientras que *ropamujer* presenta una distribución aproximadamente unimodal con ligera cola hacia valores altos. Asimismo,

variables como correo muestran una fuerte concentración en niveles elevados, lo que refuerza la hipótesis de una estrategia comercial homogénea en el envío de catálogos.

En conjunto, el análisis univariado no solo permite caracterizar estadísticamente las variables del dataset, sino también identificar implicaciones directas para las etapas posteriores del proyecto. La presencia de asimetrías pronunciadas, heterogeneidad zonal y posibles valores extremos sugiere la necesidad de considerar transformaciones, métodos robustos y validaciones cuidadosas durante la fase de modelado, con el fin de mejorar la capacidad predictiva y estabilidad del modelo final.

3.3 Análisis Exploratorio Multivariado

El análisis multivariado tiene como propósito identificar relaciones estructurales entre las variables del dataset, evaluar posibles problemas de dependencia entre predictores y detectar patrones relevantes para el modelado de la demanda. A diferencia del análisis univariado, esta etapa permite comprender cómo interactúan simultáneamente las variables operativas, comerciales y de segmentación respecto a la variable objetivo ropamujer.




Figura 3. Matriz de correlación entre variables numéricas del conjunto de entrenamiento.

La matriz de correlación evidencia que la variable objetivo **ropamujer** presenta asociaciones positivas moderadas con múltiples variables operativas, siendo **servicio** la de mayor correlación lineal ($r = 0.53$). Este resultado sugiere que una mayor disponibilidad de personal de atención y soporte comercial podría contribuir significativamente al incremento de las ventas, posiblemente debido a mejoras en la gestión de pedidos, experiencia del cliente y capacidad operativa de las zonas.

Asimismo, variables como **correo** ($r = 0.42$), **paginas** ($r = 0.38$), **telefono** ($r = 0.38$) e **impresa** ($r = 0.36$) también presentan asociaciones positivas con la demanda, indicando que la intensidad de las estrategias comerciales y publicitarias tiene un efecto relevante sobre las ventas. Sin embargo, las magnitudes moderadas de estas correlaciones sugieren que el comportamiento de la demanda no depende exclusivamente de un único factor, sino de la interacción conjunta de múltiples variables operativas y de mercado.

En contraste, la variable **nomina** presenta una correlación prácticamente nula con **ropamujer** ($r \approx 0$), resultado particularmente interesante desde la perspectiva analítica. Aunque intuitivamente podría esperarse que mayores costos operativos impliquen mercados más fuertes, la ausencia de relación lineal sugiere que el efecto de la nómina podría ser indirecto, no lineal o estar condicionado por otras variables del negocio.

Adicionalmente, la matriz revela relaciones relativamente altas entre variables predictoras, especialmente entre **correo** y **telefono** ($r = 0.75$), así como entre **correo** y **paginas** ($r = 0.65$). Este comportamiento sugiere posibles problemas de multicolinealidad, aspecto especialmente relevante para modelos de regresión lineal, ya que puede afectar la estabilidad de los coeficientes y dificultar la interpretación individual de las variables. Por esta razón, durante la fase de modelado se consideró la evaluación de métodos de selección de variables y técnicas de regularización.




Figura 4. Relación entre la variable nomina y la variable objetivo ropamujer.

El diagrama de dispersión entre nomina y ropamujer permite complementar la interpretación de la matriz de correlación al evidenciar visualmente la ausencia de una relación lineal clara entre ambas variables. Aunque existen algunas zonas con nóminas elevadas y altos niveles de ventas, la dispersión general de los datos indica que incrementos en la nómina no garantizan proporcionalmente mayores ventas. Además, se observan valores extremos en la variable nomina, lo que refuerza el hallazgo univariado sobre su fuerte asimetría positiva y sugiere que la variable podría introducir ruido o inestabilidad en modelos sensibles a outliers.

Desde la perspectiva del negocio, este resultado podría indicar que el incremento de costos operativos no necesariamente se traduce en una mejora directa de la demanda, sino que la eficiencia comercial y la asignación estratégica de recursos son factores más determinantes que el volumen absoluto de inversión en personal.

El análisis de segmentación categórica se realizó mediante diagramas de caja, con el objetivo de evaluar si existen diferencias estructurales en la distribución de ventas entre distintos tipos de mercado, tamaños potenciales y estrategias promocionales.




Figura 5. Distribución de ropamujer según tipo de mercado (idmercado).

La variable **idmercado** evidencia diferencias moderadas en la distribución de ventas entre segmentos, particularmente en los mercados 5, 7 y 8, los cuales presentan medianas ligeramente superiores y una mayor dispersión en los niveles de ventas. Este comportamiento sugiere que ciertos tipos de mercado poseen dinámicas de consumo más favorables o una mayor sensibilidad a las estrategias comerciales implementadas por Aura Chic.

La variabilidad observada entre segmentos respalda la relevancia de incorporar variables de mercado dentro del modelo predictivo, ya que las características contextuales de cada zona parecen influir directamente sobre el comportamiento de la demanda.




Figura 6. Distribución de ropamujer según tamaño potencial del mercado (tamamer).

En el caso de tamamer, las tres categorías presentan distribuciones relativamente similares en términos de mediana y rango intercuartílico; sin embargo, los mercados de mayor tamaño concentran algunos de los valores máximos más altos de ventas. Esto indica que el tamaño potencial del mercado podría influir parcialmente en la capacidad de generar altos niveles de demanda, aunque no constituye un factor completamente determinante por sí solo.

En conjunto, el análisis multivariado evidencia que la demanda de ropa de mujer responde a una combinación de variables operativas, comerciales y de segmentación, más que a un único predictor dominante. Además, los resultados permiten identificar posibles problemas de multicolinealidad, relaciones no lineales y heterogeneidad entre zonas, aspectos que deberán ser considerados durante la construcción y validación de los modelos predictivos.

3.4 Verificación de la Calidad de los Datos

La verificación de calidad de datos tuvo como propósito evaluar la confiabilidad, consistencia y viabilidad analítica del dataset antes de la etapa de modelado. Este análisis se

enfocó en cuatro dimensiones principales: completitud de la información, detección de valores atípicos, coherencia lógica de las variables y posibles implicaciones de calidad sobre la estabilidad de los modelos predictivos.

En primer lugar, el conjunto de datos no presenta valores faltantes en ninguna de las variables analizadas, lo que representa una ventaja significativa desde la perspectiva del modelado, ya que elimina la necesidad de aplicar procesos de imputación o eliminación de registros. En contextos reales de retail y ventas por catálogo, este nivel de completitud no es habitual, por lo que es razonable asumir que la información proviene de registros administrativos estructurados y relativamente consolidados.

Asimismo, no se identificaron inconsistencias lógicas evidentes, como valores negativos en variables asociadas a ventas, nómina, inversión publicitaria o recursos operativos. Las categorías de las variables cualitativas también presentan coherencia interna y no se observaron niveles desconocidos o inconsistentes en variables como promo, idmercado o tamamer. En consecuencia, la calidad estructural del dataset es adecuada para continuar con las etapas posteriores del proyecto.

No obstante, el análisis exploratorio permitió identificar múltiples valores extremos cuya interpretación resulta relevante tanto desde el punto de vista estadístico como del negocio. Más que representar errores de captura, estos valores parecen reflejar la alta heterogeneidad comercial entre zonas, característica esperable en un modelo de negocio basado en mercados geográficamente diferenciados.




Gráfico 10. Diagrama de cajas de la variable correo.

La variable **correo** presenta valores atípicos tanto inferiores como superiores respecto al rango intercuartílico. Analíticamente, este comportamiento sugiere que Aura Chic no distribuye catálogos de manera uniforme entre zonas, sino que concentra esfuerzos comerciales en determinados segmentos del mercado. Las zonas con bajos niveles de correo podrían corresponder a mercados de baja penetración o menor potencial comercial, mientras que los valores extremadamente altos podrían estar asociados a estrategias intensivas de activación comercial. Desde la perspectiva predictiva, estos extremos no se consideran problemáticos por sí mismos, aunque sí podrían incrementar la sensibilidad de modelos lineales tradicionales ante observaciones de alta influencia.




Gráfico 11. Diagrama de cajas de la variable nomina.

La variable **nomina** concentra uno de los patrones más relevantes en términos de calidad estadística. El valor máximo registrado (\$135,882 COP) supera ampliamente la mediana de la distribución y se encuentra varias desviaciones estándar por encima de la media, confirmando la fuerte asimetría positiva identificada previamente en el análisis univariado. Aunque este comportamiento podría interpretarse inicialmente como una anomalía, el contexto del negocio sugiere que estas observaciones probablemente corresponden a zonas con operaciones de gran escala, mayor densidad comercial o estructuras operativas más complejas.

Sin embargo, desde la perspectiva del modelado, este tipo de valores extremos puede generar problemas de estabilidad en algoritmos sensibles a outliers, particularmente en regresiones lineales clásicas. Por esta razón, el comportamiento de **nomina** justifica la evaluación de transformaciones de escala, técnicas robustas o métodos de regularización que reduzcan la influencia desproporcionada de estas observaciones sobre el ajuste del modelo.




Gráfico 12. Diagrama de cajas de la variable objetivo ropamujer.

En la variable objetivo ropamujer también se observan valores extremos superiores y un caso atípico inferior. Desde la perspectiva comercial, estas diferencias reflejan la existencia de zonas con desempeños excepcionalmente altos o bajos, fenómeno consistente con la heterogeneidad estructural observada a lo largo del análisis exploratorio. El valor mínimo registrado podría corresponder a una zona recientemente incorporada, una operación de bajo alcance o una observación excepcional dentro del conjunto de datos.

A diferencia de errores de captura claramente inconsistentes, estos valores extremos mantienen coherencia con la lógica del negocio y, por tanto, se conservaron en el análisis. Eliminar este tipo de observaciones podría reducir artificialmente la variabilidad real de la demanda y limitar la capacidad del modelo para generalizar adecuadamente frente a escenarios de mercado heterogéneos.

En términos generales, el análisis de calidad de datos evidencia que el dataset posee un nivel adecuado de consistencia y completitud para el desarrollo de modelos predictivos. No obstante, la presencia de asimetrías pronunciadas y observaciones extremas sugiere la necesidad de implementar estrategias de modelado robustas y validaciones cuidadosas, con

el fin de garantizar estabilidad predictiva y evitar que ciertas observaciones dominen excesivamente el comportamiento del modelo final.

4. DATA PREPARATION

4.1 Select Data

Se contó con un único archivo Excel con dos hojas: Train (1.600 registros) y Test (400 registros). Ambas hojas cubren el mismo año de operación y provienen del mismo muestreo, por lo que se integraron directamente como conjuntos de entrenamiento y evaluación sin necesidad de selección ni exclusión.

La variable idloc fue identificada como un simple identificador de zona sin poder explicativo, por lo que se excluyó únicamente de la matriz de predictores del modelo, conservándola para el archivo de sometimiento final.

4.2 Clean Data

A partir del análisis de calidad de datos realizado en la fase de comprensión (Data Understanding), se identificaron los siguientes hallazgos y las acciones de limpieza correspondientes:

Valores nulos: No se encontró ningún valor nulo en ninguna de las 12 variables del conjunto de entrenamiento (1.600 observaciones) ni en el conjunto de prueba. No obstante, como medida preventiva se implementó un paso de imputación automática: medianas para variables numéricas y moda para variables categóricas, aplicado a ambos conjuntos antes de la winsorización. Este paso no alteró ningún valor dado que no existían nulos, pero de todas formas es importante la prevención.

Filas duplicadas: No se detectaron filas duplicadas en ninguno de los dos conjuntos. No se requirió ninguna acción de deduplicación.

Error de codificación en tamamer: La variable tamamer presentó el valor "Median" en 569 registros del conjunto de entrenamiento, en lugar del texto esperado "Mediana". Este error tipográfico introducía una categoría fantasma que habría generado un nivel adicional en la variable categórica durante el modelado. Se estandarizó mediante una función de normalización que mapea "Median", "medium" y variantes similares al valor canónico "Mediana", sin importar mayúsculas ni espacios. Se aplicó la misma función al conjunto de prueba para garantizar coherencia. Tras la corrección, los niveles definitivos de tamamer son: Grande, Mediana y Pequeño.

Variables categóricas codificadas como numéricas: Las variables idmercado y promo venían almacenadas como enteros, aunque representan clases nominales (tipos de mercado y tipos de promoción). Se convirtieron a tipo factor (categórico) en ambos conjuntos. Esta conversión es necesaria para que el motor de modelado genere correctamente las variables dummy y no interprete los códigos como magnitudes ordenadas.

Valores atípicos (Winsorización): Mediante la regla de Tukey se detectaron outliers en tres variables: correo (122 observaciones), nomina (69 observaciones) y ropamujer (9 observaciones). Se optó por winsorización en lugar de eliminación, conservando todas las observaciones y reduciendo el efecto de los extremos sin introducir sesgo por exclusión. Los cuantiles de referencia se aprendieron exclusivamente del conjunto de entrenamiento y se aplicaron de forma idéntica al conjunto de prueba.

Para las variables numéricas originales (correo, nomina, telefono, paginas, impresa, servicio, edadloc) se aplicó winsorización al percentil 1–99 en ambos conjuntos. Para la variable objetivo ropamujer se aplicó winsorización al percentil 2–98 únicamente en entrenamiento; este límite más estricto busca reducir la influencia de los 9 valores extremos sobre la función de pérdida cuadrática. Adicionalmente, tras el proceso de ingeniería de

variables, se aplicó winsorización p1–p99 también sobre todas las variables derivadas e interacciones, garantizando que los nuevos predictores no introduzcan extremos artificiales.

variable ropamujer fue winsorizada únicamente en entrenamiento, dado que en prueba es la variable objetivo desconocida.

4.3 Construct Data (Feature Engineering)

Con el objetivo de capturar relaciones no lineales, efectos de umbral y sinergias entre predictores, se construyeron nuevas variables organizadas en ocho grupos. Los estadísticos de referencia (percentiles para splines, medias y desviaciones para el índice) se calcularon exclusivamente sobre el conjunto de entrenamiento y se aplicaron de forma idéntica al conjunto de prueba.

- **Transformaciones logarítmicas:** Se aplicó $\log_{1p}$ a servicio, correo, impresa, edadloc y telefono, corrigiendo la asimetría positiva de sus distribuciones. La suma de 1 previene problemas con valores en cero.
- **Splines lineales truncados:** Para servicio, correo, paginas, impresa, telefono y edadloc se crearon 4 splines truncados en los percentiles 20, 40, 60 y 80 del entrenamiento (24 variables en total: srv_k1-k4 , cor_k1-k4 , pag_k1-k4 , imp_k1-k4 , tel_k1-k4 , $edad_k1-k4$). Permiten capturar cambios de pendiente en distintos tramos de la variable sin abandonar el marco lineal.
- **Términos polinómicos:** Cuadráticos para servicio, correo, paginas, telefono, impresa y edadloc ($srv2$, $cor2$, $pag2$, $tel2$, $imp2$, $edad2$); cúbicos para servicio, correo y paginas ($srv3$, $cor3$, $pag3$).
- **Interacciones de dos variables:** Diez productos entre pares de predictores: $srv \times cor$, $srv \times tel$, $srv \times imp$, $srv \times pag$, $srv \times edad$, $cor \times tel$, $cor \times pag$, $cor \times imp$, srv_cor_tel (triple), srv_cor_pag (triple). Las dos últimas son interacciones de tres variables seleccionadas por el stepwise en rondas previas.
- **Ratios:** Cuatro cocientes de intensidad relativa: $servicio/(correo/1000)$, $impresa/(correo/1000)$, $paginas/(telefono+1)$, $servicio/(paginas+1)$.

- **Codificaciones de variables categóricas e interacciones:** tamamer se codificó ordinalmente (Pequeño=1, Mediano=2, Grande=3) como tamamer_ord; idmercado y promo se extrajeron como numéricos (idmercado_num, promo_num). Se generaron interacciones de cada codificación con servicio, correo, paginas e impresa (tam_x_srv, tam_x_cor, tam_x_pag, tam_x_imp; mkt_x_srv, mkt_x_cor, mkt_x_pag, mkt_x_srv2; promo_x_srv, promo_x_cor, promo_x_pag, promo_x_imp), más interacciones spline×factor en el percentil 80 de servicio (mkt_x_srv_k4, tam_x_srv_k4, promo_x_srv_k4).

- **Indicador correo_bajo e interacciones:** Se creó el indicador binario correo_bajo (correo < 3.000) y su interacción con servicio (correo_bajo_srv), dado que las zonas con muy bajo volumen de catálogos muestran un patrón diferenciado de ventas.

- **Indicador es_promo2 e interacciones:** Se creó el indicador binario es_promo2 (promo = 2) y 10 interacciones asociadas: es_promo2×servicio, ×correo, ×paginas, ×impresa, ×telefono, ×servicio², ×correo², ×srv_k2, ×srv_k3 y ×srv_k4, dada la mayor varianza de ropamujer observada en zonas con ese tipo de promoción.

- **Índice compuesto de marketing:** marketing_idx es la suma de los z-scores estandarizados de correo, paginas, telefono, impresa y servicio, más su cuadrado (mkt_idx2), como proxy del esfuerzo comercial agregado de cada zona.

4.4 Variable excluida: idloc fue excluida del conjunto de predictores por ser un simple identificador de zona sin valor explicativo. Se retuvo únicamente para construir el archivo de sometimiento.

4.5 Integrate Data

No aplica. El análisis se realizó sobre una única fuente de datos (el archivo Excel provisto), por lo que no fue necesario integrar fuentes externas ni realizar joins entre conjuntos independientes.

4.6 Dataset Description Dataset Final

Tras los procesos de limpieza e ingeniería de variables, el dataset de entrenamiento tiene la siguiente estructura:

Variable	Tipo	Descripción
idloc	Identificador (excluido)	ID único
edadloc	Numérica continua	Años desde llegada a la zona
correo	Numérica continua	Catálogos enviados en el año
paginas	Numérica continua	Páginas del catálogo
telefono	Numérica continua	Líneas de atención promedio
impresa	Numérica continua	Gasto en publicidad impresa
servicio	Numérica continua	Representantes de servicio
nomina	Numérica continua	Nómina total del año
idmercado	Categórica nominal	Tipo de mercado (9 clases)
tamamer	Categórica ordinal	Tamaño del mercado potencial

promo	Categórica nominal	Tipo de promoción (3 clases)
ropamujer	Numérica continua (objetivo)	Ventas ropa mujer (millones COP)
log_srv, log_cor, log_imp, log_edad, log_tel	Numérica derivada	log1p de las respectivas variables
srv_k1–k4, cor_k1–k4, pag_k1–k4, imp_k1–k4, tel_k1–k4, edad_k1–k4	Numérica derivada	Splines truncados en p20/p40/p60/p80 (24 variables)
srv2, cor2, pag2, tel2, imp2, edad2	Numérica derivada	Términos cuadráticos
srv3, cor3, pag3	Numérica derivada	Términos cúbicos
srv×cor, srv×tel, srv×imp, srv×pag, srv×edad, cor×tel, cor×pag, cor×imp	Interacción 2 variables	Productos entre pares de predictores clave

srv_cor_tel, srv_cor_pag	Interacción 3 variables	Productos triples seleccionados por Stepwise
srv/(cor/1000), imp/(cor/1000), pag/(tel+1), srv/(pag+1)	Ratio	Cocientes de intensidad relativa de recursos
tamamer_ord, tam×srv, tam×cor, tam×pag, tam×imp, tam×srv_k4	Encoding ordinal + interacciones	Tamaño de mercado numérico y sus productos
idmercado_num, mkt×srv, mkt×cor, mkt×pag, mkt×srv2, mkt×srv_k4	Encoding numérico + interacciones	Mercado numérico y sus productos
promo_num, promo×srv, promo×cor, promo×pag, promo×imp, promo×srv_k4	Encoding numérico + interacciones	Promo numérico y sus productos
correo_bajo, correo_bajo_srv	Indicador binario + interacción	Indicador correo < 3.000 y su producto con servicio

es_promo2 + 10 interacciones (×srv, ×cor, ×pag, ×imp, ×tel, ×srv2, ×cor2, ×srv_k2, ×srv_k3, ×srv_k4)	Indicador binario + interacciones	Indicador promo=2 y sus efectos diferenciados
marketing_idx, mkt_idx2	Índice compuesto	Suma de z-scores de 5 variables comerciales y su cuadrado

Dimensiones finales: 1.600 observaciones × ~80 variables predictoras (más ropamujer como objetivo) en entrenamiento; 400 observaciones × ~80 variables predictoras en prueba.

5. MODELLING & EVALUATION

5.1 Select Modeling Techniques

Se seleccionaron dos técnicas de modelado lineal evaluadas en paralelo: Regresión por pasos (Stepwise OLS) y LASSO puro ($\alpha = 1$). En Rondas 1–4 el Stepwise usa el criterio AIC por defecto; a partir de la Ronda 7 se usa el criterio BIC ($k = \log(n)$), más estricto, para favorecer parsimonia en el espacio ampliado de ~80 predictores. El modelo ganador de cada ronda se selecciona automáticamente por menor RMSE en validación cruzada de 10 folds.

Justificación de la selección:

- La variable objetivo ropamujer es continua, lo que hace adecuada la familia de modelos lineales regularizados o por selección de variables.

- El espacio expandido de ~80 predictores eleva el riesgo de sobreajuste y multicolinealidad. LASSO lo maneja mediante penalización L1 que lleva coeficientes a cero. Stepwise controla la complejidad incluyendo solo variables que mejoran el criterio de información.
- La comparación sistemática entre ambas técnicas garantiza que la elegida es la que mejor generaliza en cada iteración.

Verificación de supuestos del modelo lineal:

- **Linealidad:** Las correlaciones de Pearson con ropamujer son moderadas-altas (servicio: 0.53, correo: 0.42, paginas: 0.38). Los splines y los términos polinómicos permiten capturar desviaciones de la linealidad sin abandonar el marco lineal en parámetros.
- **Multicolinealidad:** La creación de splines, cuadráticos e interacciones genera correlación alta entre predictores. LASSO la resuelve eliminando variables redundantes; Stepwise la controla mediante selección secuencial penalizada por criterio de información.
- **Homocedasticidad e independencia:** Se asume independencia aproximada entre zonas. La winsorización contribuye a estabilizar la varianza del error.
- **Normalidad de residuos:** No es un supuesto estricto para la minimización del error cuadrático en muestras grandes ($n = 1.600$).

5. 2 Generate Test Design

Partición de datos: Se utilizó la partición proveída por la competencia: 1.600 observaciones para entrenamiento (Train) y 400 para evaluación final (Test, sin ropamujer conocida). No se realizó una partición adicional de validación interna porque el mecanismo de validación cruzada proporciona una estimación más robusta del error generalizado.

Validación cruzada K-fold ($K = 10$): El conjunto de entrenamiento se dividió en 10 pliegues (folds) de igual tamaño. En cada iteración, 9 pliegues se usan para ajustar el modelo y 1 para evaluar. El RMSE reportado en entrenamiento es el promedio de los 10

folds, lo que proporciona una estimación del error de generalización menos sesgada que la evaluación sobre el mismo conjunto de entrenamiento.

Control del sobreajuste: En las rondas 1-4, Stepwise AIC penaliza cada variable adicional con $k = 2$, controlando la complejidad del modelo. En la Ronda 7 se cambia a Stepwise BIC ($k = \log(n) \approx 7.38$), criterio más estricto que impone un umbral más alto para incluir cada predictor. LASSO controla el sobreajuste mediante penalización L1, llevando a cero los coeficientes de variables no informativas. El lambda óptimo de LASSO se elige por `cv.glmnet`.

Selección de variables (feature selection): La penalización Lasso inherente a Elastic Net lleva automáticamente algunos coeficientes exactamente a cero, realizando selección implícita de variables. No se realizó un filtrado previo basado en p-valores o importancia de variables para evitar sesgos de selección.

Mecanismo de comparación: En cada ronda se ajustan Stepwise y LASSO sobre el mismo conjunto de entrenamiento con CV-10. El modelo con menor RMSE de CV se usa para generar las predicciones de Kaggle de esa ronda. La selección es automática: si `cv_step$RMSE <= rmse_cv_lasso` se elige Stepwise, de lo contrario LASSO.

5.3 Build Model

El proceso de entrenamiento se implementó con los paquetes MASS, caret y glmnet de R. A continuación se describe la parametrización de cada técnica:

Técnica	Hiperparámetro	Valor	Criterio
---------	----------------	-------	----------

Stepwise OLS (Rondas 1–4)	Criterio de información	AIC ($k = 2$)	Penaliza complejidad por defecto de stepAIC; selecciona variables que reducen el AIC
Stepwise OLS (Ronda 7)	Criterio de información	BIC ($k = \log(n) \approx 7.38$)	Más estricto que AIC; favorece parsimonia en espacio amplio de ~80 predictores
Stepwise OLS	Dirección de búsqueda	Both (forward + backward)	Permite incluir y excluir variables en cada paso
LASSO	alpha	1 (Lasso puro)	Penalización L1; coeficientes de variables irrelevantes van exactamente a cero

5.4 Assess Model

Se presenta a continuación la evaluación comparativa de los modelos por ronda, medidos por RMSE en validación cruzada

Ronda	Técnica	RMSE CV-Train

Ronda 1	Stepwise CV	10,776.79
Ronda 2	Stepwise CV	10,655.56
Ronda 3	Stepwise CV	10,460.63
Ronda 4	Stepwise CV	10,441.51
Ronda 5	Lasso CV	10,649.09

Análisis de resultados:

- **Mejora iterativa:** se redujo el RMSE de CV de 10.776 (Ronda 1) a 10.460 (Ronda 3). La adición de splines truncados fue el salto más relevante entre rondas.
- **Cambio de criterio AIC → BIC en Ronda 4:** El paso a BIC ($k = \log(n)$) impone un umbral más estricto para incluir variables, produciendo un modelo más parsimonioso sobre el espacio ampliado de ~80 predictores y reduciendo el sobreajuste.
- **Winsorización p2–p98 en ropamujer:** El límite más estricto en la variable objetivo minimiza la influencia de sus 9 outliers más extremos sobre la función de pérdida cuadrática.
- **Indicadores correo_bajo y es_promo2:** La segmentación explícita de zonas con correo < 3.000 y de zonas con promo=2 permite que el modelo capture patrones de demanda diferenciados que las interacciones continuas no recogen completamente.

- **Selección automática por ronda:** En cada ronda el ganador (Stepwise vs. LASSO) se elige por menor RMSE de CV-10, garantizando que la técnica seleccionada es la que mejor generaliza para el espacio de variables de esa iteración.
- **Impacto en KPI de negocio:** El RMSE de las rondas avanzadas representa un error porcentual aproximado del 20% respecto a la venta media (~50.978 M COP), razonable para pronósticos anuales con alta heterogeneidad entre zonas. El modelo apoya la asignación eficiente de recursos por zona.

Modelo final seleccionado: Stepwise OLS con criterio BIC ($k = \log(n)$), ajustado sobre el dataset con winsorización p2–p98 en ropamujer, p1–p99 en variables numéricas originales y derivadas, y el feature engineering completo de la Ronda 4.

6. DEPLOYMENT

6.1 Estrategias Sugeridas para el Logro de los Objetivos de Negocio

Con base en los hallazgos obtenidos durante el análisis exploratorio y el modelado predictivo, se plantean estrategias orientadas a mejorar el desempeño comercial de Aura Chic mediante una asignación más eficiente de recursos operativos y de marketing. Estas estrategias se alinean con el enfoque de las **4Ps actualizadas de Kotler**, particularmente con el componente **Programs**, entendido como el conjunto integrado de actividades comerciales, promocionales y operativas que generan valor para el cliente.

Objetivo de Negocio 1 (ON1)

Mejorar la capacidad de pronóstico de ventas para optimizar la planeación comercial y la asignación de recursos entre zonas.

Estrategia 1 — Implementación de pronósticos zonales para planeación operativa

El modelo predictivo desarrollado puede utilizarse para estimar anticipadamente la demanda anual de ropa de mujer en cada zona comercial. Esto permitiría ajustar de manera

más eficiente la distribución de inventario, la asignación de catálogos y la planeación logística, reduciendo riesgos de sobrestock o desabastecimiento.

Estrategia 2 — Priorización comercial basada en demanda esperada

Aura Chic puede utilizar las predicciones del modelo para clasificar las zonas según potencial de ventas y asignar recursos de manera diferenciada. Las zonas con mayor demanda proyectada podrían recibir campañas comerciales más intensivas, mayor cobertura de servicio y catálogos especializados.

Estrategia 3 — Monitoreo continuo del desempeño comercial

Se recomienda implementar un sistema de seguimiento periódico que compare ventas reales frente a ventas proyectadas por zona. Esto permitiría detectar desviaciones tempranas y ajustar rápidamente las estrategias comerciales y operativas.

Objetivo de Negocio 2 (ON2)

Identificar las variables comerciales y operativas que tienen mayor impacto sobre las ventas para fortalecer las estrategias de marketing y servicio.

Estrategia 1 — Fortalecimiento del servicio al cliente

El análisis mostró que la variable **servicio** es una de las más relevantes para explicar la demanda. Por ello, se recomienda fortalecer programas de capacitación de representantes, mejorar tiempos de atención y optimizar los canales de soporte comercial en zonas estratégicas.

Estrategia 2 — Optimización segmentada de campañas de correo y publicidad

Variables como **correo**, **telefono** e **impresa** mostraron asociaciones positivas con las ventas. Sin embargo, el análisis también evidenció heterogeneidad entre mercados, por lo que se recomienda segmentar las campañas comerciales según tipo de mercado y tamaño potencial de la zona, evitando estrategias homogéneas.

Estrategia 3 — Diseño de catálogos diferenciados por segmento

Los resultados sugieren que algunos mercados responden de forma distinta a las estrategias comerciales. Por esta razón, Aura Chic podría desarrollar catálogos personalizados según características del mercado objetivo, ajustando promociones, productos destacados y número de páginas según el perfil de cada zona.

Objetivo de Negocio 3 (ON3)

Fortalecer el uso de analítica de datos como herramienta estratégica para la toma de decisiones comerciales.

Estrategia 1 — Integración de dashboards analíticos

Se recomienda desarrollar paneles interactivos que permitan visualizar predicciones, desempeño de zonas y métricas comerciales en tiempo real para apoyar la toma de decisiones gerenciales.

Estrategia 2 — Expansión del modelo a otras líneas de producto

La metodología desarrollada podría replicarse para pronosticar ventas de joyería o ropa masculina, permitiendo construir un sistema integral de analítica comercial multiproducto.

Estrategia 3 — Cultura organizacional orientada a datos

Aura Chic puede fortalecer procesos de toma de decisiones basados en evidencia, promoviendo el uso de modelos predictivos en áreas comerciales, de marketing y planeación estratégica.

6.2 Análisis Costo–Beneficio de las Estrategias

Desde la perspectiva financiera y operativa, la implementación de modelos predictivos y estrategias comerciales segmentadas puede generar beneficios significativos en eficiencia y rentabilidad.

En primer lugar, el uso de pronósticos zonales permitiría reducir errores en la asignación de inventario y recursos comerciales. Suponiendo que la empresa logre mejorar en un 8% las ventas de las zonas de mayor potencial gracias a una mejor planeación y focalización de campañas, el impacto económico sería considerable.

Tomando como referencia la venta promedio anual por zona (\$50,978 COP) y considerando intervención sobre aproximadamente el 20% de las zonas (320 zonas), el beneficio potencial sería:

$$50,978 \times 320 \times 0.08 = 1.3 \text{ millones COP}$$

Este beneficio podría superar ampliamente los costos asociados a:

- capacitación comercial,
- implementación de dashboards,
- mantenimiento del modelo,
- y fortalecimiento de infraestructura analítica.

Adicionalmente, una asignación más eficiente de campañas de correo y publicidad permitiría reducir gastos en zonas de baja respuesta comercial, mejorando el retorno marginal de las inversiones en marketing.

Desde la perspectiva de las 4Ps actualizadas de Kotler, estas estrategias fortalecen especialmente el componente **Programs**, ya que integran analítica, operaciones y marketing dentro de un sistema coordinado de toma de decisiones orientado al desempeño comercial.

6.3 Potenciales Siguiendo Pasos de Análisis

Aunque el modelo final presenta resultados satisfactorios, existen múltiples oportunidades de mejora y expansión analítica que podrían incrementar la capacidad predictiva y el valor estratégico del sistema desarrollado.

Incorporación de variables externas

El dataset actual se basa principalmente en variables internas de operación y marketing. Futuras versiones del modelo podrían enriquecerse incorporando:

- variables socioeconómicas,
- PIB municipal,
- penetración de e-commerce,
- niveles de informalidad laboral,
- densidad poblacional,
- y datos de competencia regional.

Estas variables permitirían capturar factores externos que influyen sobre el comportamiento de la demanda.

Evaluación de modelos no lineales avanzados

Aunque el modelo Stepwise BIC obtuvo el mejor desempeño dentro de las técnicas evaluadas, la presencia de relaciones no lineales y heterogeneidad entre zonas sugiere explorar modelos más complejos como:

- Random Forest,
- Gradient Boosting,
- XGBoost,
- y redes neuronales.

Estos modelos podrían capturar interacciones más complejas entre variables y mejorar el desempeño predictivo.

Segmentación analítica de mercados

Los análisis por **idmercado** y **tamamer** evidenciaron diferencias estructurales entre segmentos. Por ello, un siguiente paso relevante consiste en construir modelos diferenciados por clústeres o tipos de mercado, permitiendo desarrollar estrategias comerciales más personalizadas.

Monitoreo y mantenimiento del modelo

Finalmente, se recomienda implementar un sistema de monitoreo continuo del desempeño predictivo mediante métricas como RMSE y MAPE. Esto permitiría detectar degradación del modelo ante cambios en las condiciones del mercado y actualizar periódicamente el sistema predictivo para mantener su capacidad de generalización.

7. Conclusiones Generales

La aplicación estructurada de la metodología CRISP-DM permite transformar datos operativos de retail en herramientas analíticas con valor estratégico para la toma de decisiones comerciales. A través del desarrollo de modelos predictivos para pronóstico de ventas de ropa de mujer por zona, fue posible identificar patrones relevantes de demanda, relaciones entre variables comerciales y oportunidades de optimización para Aura Chic.

El análisis exploratorio evidenció una alta heterogeneidad entre zonas comerciales, tanto en niveles de ventas como en intensidad operativa y estrategias de marketing. Variables como servicio, correo, telefono, paginas e impresa mostraron relaciones positivas con la demanda, mientras que nomina presentó un comportamiento altamente asimétrico y prácticamente nula correlación lineal con las ventas. Estos hallazgos fueron fundamentales para justificar las decisiones de feature engineering y selección de variables implementadas durante el modelado.

Desde la perspectiva técnica, el modelo final seleccionado fue un Stepwise OLS con criterio BIC, entrenado sobre un conjunto expandido de aproximadamente 80 variables

derivadas, interacciones y transformaciones. Este modelo alcanzó un RMSE cercano a 10,441 COP en validación cruzada de 10 folds, mostrando mejoras progresivas frente a las primeras rondas y evidenciando una adecuada capacidad de generalización.

Uno de los hallazgos más relevantes del proyecto es que la calidad operativa y el nivel de servicio parecen tener un impacto más consistente sobre la demanda que algunas variables tradicionales de inversión publicitaria. Esto sugiere que la ventaja competitiva de Aura Chic no depende únicamente de aumentar el gasto comercial, sino de mejorar la eficiencia operativa, la segmentación de mercados y la personalización de estrategias por zona.

Asimismo, el proyecto permitió identificar desafíos importantes asociados al modelado de datos comerciales reales, incluyendo presencia de valores extremos, posibles problemas de multicolinealidad y relaciones no lineales entre variables. La implementación de winsorización, splines, interacciones y regularización fue clave para controlar estos efectos y construir un modelo más estable.

Finalmente, el proyecto evidencia que la analítica predictiva puede convertirse en un activo estratégico para Aura Chic, no solo como herramienta de pronóstico, sino como mecanismo para optimizar inventarios, priorizar zonas comerciales y mejorar la asignación de recursos. Más allá de la precisión estadística alcanzada, el principal aporte del trabajo radica en demostrar cómo los datos pueden apoyar decisiones empresariales más informadas, eficientes y orientadas al crecimiento sostenible del negocio.

Referencias

CCCE (Cámara Colombiana de Comercio Electrónico). (2020). Informe de comercio electrónico en Colombia 2020. Bogotá: CCCE.

DANE (Departamento Administrativo Nacional de Estadística). (2020). Cuentas nacionales: PIB por sectores. Bogotá: DANE.

Euromonitor International. (2020). Apparel and Footwear in Colombia. London: Euromonitor.

Inexmoda. (2020). Observatorio Económico de la Moda Colombiana 2020. Medellín: Inexmoda.

Kotler, P., & Keller, K. L. (2016). *Marketing Management* (15th ed.). Pearson.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29-39.